

<p><b>בעיית הריבועים הפחותים:</b> <math>x \in \mathbb{R}^n, b \in \mathbb{R}^m, \text{full rank } A \in \mathbb{R}^{m \times n}</math>  אנו מחפשים וקטור <math>x</math> כך ש-<math>Ax</math> יהיה כמה שיותר קרוב ל-<math>b</math>.  <math>* Ax - b = r(x)</math> וקטור השארית.  <math>*   Ax - b  _2^2 = \arg \min_{x \in \mathbb{R}^n}</math> הוא הוקטור האופטימלי או בכתיב מטריצוני <math>\hat{x} = (A^T A)^{-1} A^T b</math> (כאשר <math>A</math> היא full rank)  <math>A^T Ax = A^T b</math> הן המשוואות הנורמליות, אם <math>A</math> אינה full rank אז יש להן אינסוף פתרונות.  * עבור קבוצות נק' <math>(x_i, y_i)</math> נרצה למצוא ישר <math>ax + b</math> העובר כמה שיותר קרוב לנק'.  נפתור זאת כך: ונקבל:</p> $\begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} m & \sum_i x_i \\ \sum_i x_i & \sum_i x_i^2 \end{bmatrix}^{-1} \begin{bmatrix} \sum_i y_i \\ \sum_i x_i y_i \end{bmatrix}$ $\arg \min_{a,b} \left\  \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} - \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \right\ _2$ <p>* ניתן להוסיף משקולות לבעיה ע"י מטריצה <math>W</math> שהיא SPD ולקבל <math>\hat{x} = (A^T W A)^{-1} A^T W b</math> <math>\hat{x} = \arg \min_{x \in \mathbb{R}^n}   Ax - b  _W^2</math>  * אם <math>A</math> סינגולרית ניתן להוסיף רגולריזציה לבעיה באמצעות <math>\lambda &gt; 0</math> ומטריצה <math>C</math> (בדרך <math>C = I</math>) ולקבל:  <math>\hat{x} = \arg \min_{x \in \mathbb{R}^n}   Ax - b  _2^2 + \lambda   Cx  _2^2</math>  או <math>\hat{x} = (A^T A + \lambda C^T C)^{-1} A^T b</math>  <b>טענה:</b> כל משוואה ריבועית ניתן לכתוב כך: <math>x^T Ax + x^T b</math>  <b>מינימום ריבועים ע"י SVD:</b> <math>\hat{x} = \arg \min_{x \in \mathbb{R}^n}   U \Sigma V^T x - b  _2^2</math>  כאשר <math>A</math> היא full rank אז <math>\hat{x} = V(\Sigma)^{-1} U^T b</math>  כאשר <math>A</math> לא full rank אז <math>\hat{x} = V(\Sigma)^\dagger U^T b</math>  עבור <math>(\Sigma)^\dagger = \begin{cases} (\Sigma_{i,i})^{-1} &amp; \Sigma_{i,i} \neq 0 \\ 0 &amp; \Sigma_{i,i} = 0 \end{cases}</math></p>	<p><b>נורמה וקטורית:</b> <math>   \cdot   </math> תקרא נורמה אם מתקיים:  * אי שליליות: <math>  \vec{x}   \geq 0</math> או <math>  \vec{x}   = 0 \Leftrightarrow \vec{x} = 0</math>  * הומוגניות: <math>  \lambda \vec{x}   =  \lambda    \vec{x}  , \lambda \in \mathbb{R}, \vec{x} \in \mathbb{R}^n</math>  * אי שוויון המשולש: <math>  \vec{x} + \vec{y}   \leq   \vec{x}   +   \vec{y}  </math>  <b>קבוצת נורמות LP:</b> <math>  \vec{v}  _p = (\sum_{i=1}^n  v_i ^p)^{\frac{1}{p}}</math>  למשל: <math>  \vec{v}  _1 = \sum_{i=1}^n  v_i ,   \vec{v}  _\infty = \max_i \{ v_i \}</math>  <math>  \vec{v}  _2 = (\sum_{i=1}^n v_i^2)^{\frac{1}{2}} = \sqrt{v^T v} = \sqrt{\langle v, v \rangle}</math>  נשים לב כי <math>  \vec{v}  _2 \leq   \vec{v}  _\infty</math>  <b>נורמת אנרגיה:</b> לכל מטריצה <math>M</math> מסוג SPD תוגדר הנורמה <math>  \vec{v}  _M = \sqrt{\langle \vec{v}, M \vec{v} \rangle}</math>  <b>טענה:</b> מטריצה אורתוגונלית משמרת נורמה וקטורית <math>  \cdot  _2</math> ומתקיים: <math>  Q\vec{v}  _2 =   \vec{v}  _2</math>  <b>טענה:</b> כל נורמה <math>  \cdot  </math> היא פונקציה רציפה (לא בהכרח גזירה).  <b>טענה:</b> לכל נורמות וקטוריות <math>\phi_1, \phi_2</math> קיימים קבועים <math>0 &lt; a \leq b</math> ומתקיים <math>a\phi_2(\vec{v}) \leq \phi_1(\vec{v}) \leq b\phi_2(\vec{v})</math>  (כלומר כל הנורמות שקולות, אם באחת נתכנס ל-0 אז גם בשניה).</p>	<p><b>ע"ע ו-ו"ע:</b> <math>v</math> ו"ע ל-<math>u</math> ע"ע <math>\lambda</math> ב-<math>A</math> <math>Av = \lambda v \Leftrightarrow</math>  <b>רדיוס ספקטרילי:</b> <math>\rho(A) = \max_{1 \leq i \leq n}  \lambda_i </math>  <math>\forall \lambda_n: \rho(A) \leq   A^K  ^{\frac{1}{K}}</math>  <b>ערך סינגולרי:</b> <math>\sigma_i</math> עבור <math>\lambda_i</math> ע"ע של <math>A^T A</math>  <b>פירוק ספקטרילי:</b> אם <math>A</math> ל-<math>A</math> יש <math>n</math> ו"ע עם ע"ע שונים אז <math>A</math> לכסינה: <math>A = V \Lambda V^{-1}, \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)</math>  <math>V = [v_1   \dots   v_n]</math>  <b>פירוק נורמלי:</b> אם <math>A</math> נורמלית אז קיימת <math>U \in \mathbb{C}^{n \times n}</math> אוניטרית: <math>U^* U = I, A = U \Lambda U^*</math>  <math>U = [u_1   \dots   u_n], \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n); \lambda_i \in \mathbb{C}</math>  <b>חיובית מוגדרת:</b> <math>x^T A x &gt; 0 \forall x \in \mathbb{R}^n</math>  <b>(SPD)</b> מטריצה סימטרית חיובית מוגדרת <math>(\lambda_i &gt; 0)</math>  <b>חיובית חצי מוגדרת:</b> <math>x^T A x \geq 0 \forall x \in \mathbb{R}^n</math>  (מתקיים לכל <math>A^T A</math> כאשר <math>A</math> מדרגה מלאה)  <b>מטריצה הפיכה:</b> קיים <math>A^{-1} \Leftrightarrow \det(A) \neq 0</math>  לא סינגולרית <math>A \Leftrightarrow</math> full rank <math>A</math>  <b>טענה:</b> <math>\det(A) = 0 \Leftrightarrow \det(A) = 0</math> או <math>\det(B) = 0</math>  <b>טענה:</b> עבור חיובית מוגדרת / הפיכה / לכסינה, אם <math>Av_i = \lambda_i v_i</math> אז <math>A^{-1} v_i = (1/\lambda_i) v_i</math>  <b>טענה:</b> עבור <math>A \in \mathbb{R}^{2 \times 2}</math> מהצורה <math>\begin{pmatrix} a &amp; b \\ b &amp; c \end{pmatrix}</math> אם <math>a &gt; 0; c &gt; 0; a &gt; b; c &gt; b</math> אז <math>SPD</math> <math>A</math>  <b>נורמלית:</b> <math>A^T A = A A^T</math>  <b>תלת אלכסונית:</b> <math>a_{i,j} = 0</math> if <math> i - j  &gt; 1</math>  <b>strictly diagonally dominant (SDD):</b> מטריצה <math>A</math> אשר מקיימת <math> a_{j,j}  &gt; \sum_i  a_{i,j} </math> או <math> a_{i,i}  &gt; \sum_j  a_{i,j} </math>  <b>דטרמיננט:</b> <math>\det(AB) = \det(A) \det(B)</math>  * אם <math>L</math> היא מטריצה משולשית אז <math>\det(L) = \prod_i l_{i,i}</math>  * עבור <math>A = \begin{pmatrix} a &amp; b \\ c &amp; d \end{pmatrix}</math> נקבל <math>\det(A) = ad - bc</math>  <b>חוקי מטריצות:</b>  * <math>(AB)^{-1} = B^{-1} A^{-1}</math> עבור <math>A, B</math> ריבועיות  <math>(AB)^T = B^T A^T</math>  <math>(A + B)^T = A^T + B^T</math>  <b>סכום מטריצות ו-ע"ע:</b>  * עבור מטריצות <math>A, B</math> בעלי אותו ו"ע: <math>(A + B)v = Av + Bv = \lambda_A v + \lambda_B v = (\lambda_A + \lambda_B)v</math></p>
<p><b>תהליך Gram Schmidt:</b> <math>A = [a_1   \dots   a_n]</math> ניצור מטריצה אורתוגונלית <math>Q</math> בהתבסס על עמודות <math>A</math> כך: <math>q_i = a_i - \sum_{j=1}^{i-1} \frac{\langle a_i, a_j \rangle}{\langle a_j, a_j \rangle} a_j</math>  <b>פירוק QR:</b> באמצעות גרהאם שמידט עם נימול נפרק מטריצה <math>A = QR</math> למטריצה <math>Q</math> אורתוגונלית ו-<math>R</math> משולשית עליונה.  <b>Algorithm: Gram Schmidt QR</b>  <math>\# A = [a_1   a_2   \dots   a_n] \in \mathbb{R}^{m \times n}</math>  Initialize: <math>R = 0^{n \times n}, R_{1,1} =   a_1  _2, q_1 = \frac{a_1}{R_{1,1}}</math>  <b>for</b> <math>i = 2, \dots, n</math> <b>do</b>      <math>q_i \leftarrow a_i</math>      <b>for</b> <math>j = 1 : i - 1</math> <b>do</b>          <math>R_{j,i} = q_j^T a_i</math>          <math>q_i \leftarrow q_i - R_{j,i} q_j</math>      <b>end</b>      <math>R_{i,i} =   q_i  _2</math>      <math>q_i \leftarrow \frac{q_i}{R_{i,i}}</math>  <b>end</b></p>	<p><b>נורמת מטריצה:</b> (מקיימות את אותן תכונות של נורמות וקטוריות)  <b>נורמות מטריצות אנאלוגיות לנורמות וקטוריות:</b>  * <b>Forbenius Norm:</b> <math>  A  _F = (\sum_i \sum_j  a_{i,j} ^2)^{\frac{1}{2}}</math>  * <math>  A  _F = \sqrt{\text{trace}(A A^T)}</math>  * <math>  A  _1 = \sum_{i,j}  a_{i,j} </math>  * <math>  A  _\infty = \max_{i,j}  a_{i,j} </math>  <b>נורמות מטריצות מושרות:</b>  <math>  A  _a =   A  _{a,b}</math> יסומן <math>  A  _a = \max_{x \in \mathbb{R}^n} \frac{  Ax  _a}{  x  _b}</math>  <b>דוגמאות:</b> <math>  A  _1 = \max_j (\sum_{i=1}^n  a_{i,j} )</math>  <math>  A  _\infty = \max_i (\sum_{j=1}^n  a_{i,j} )</math>  <b>טענה:</b> <math>  A\vec{x}  _a \leq   A  _{a,b}   \vec{x}  _b</math> כאשר <math>\mu_i</math> ע"ע של <math>A^T A</math>  <b>טענה:</b> <math>  AB  _{b,a} \leq   A  _{c,a}   B  _{b,c}</math>  <b>טענה:</b> עבור <math>A</math> נורמלית מתקיים <math>  A  _2 = \rho(A)</math></p>	<p><b>נגזרות:</b> <math>M \in \mathbb{R}^{n \times n}, A \in \mathbb{R}^{m \times n}, x, v \in \mathbb{R}^n</math>  * גרדיאנט של <math>f(x_1, \dots, x_n)</math> הוא <math>\nabla f = [\frac{\partial f}{\partial x_1} \dots \frac{\partial f}{\partial x_n}]^T</math>  * <math>\nabla f = v</math> אז <math>f = v^T x</math>  * <math>\nabla f = 2x</math> אז <math>f = x^T x</math>  * <math>\nabla f = A^T A v</math> אז <math>f = v^T A^T A x</math>  * <math>\nabla f = 2A^T A x</math> אז <math>f = x^T A^T A x</math>  * <math>\nabla f = (M + M^T)x</math> אז <math>f = x^T M x</math></p>
<p><b>פירוק SVD:</b> לכל <math>A \in \mathbb{R}^{m \times n}, p = \min(m, n)</math>, קיימות מטריצות אורתוגונליות <math>U \in \mathbb{R}^{m \times p}, V \in \mathbb{R}^{n \times p}</math> ומטריצה אלכסונית <math>\Sigma \in \mathbb{R}^{p \times p} = \text{diag}(\sigma_1, \dots, \sigma_p)</math> ומתקיים <math>A = U \Sigma V^T</math> כך שמתקיים: <math>\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p</math>  <ul style="list-style-type: none"> <li><math>\sigma_i</math> הם שורשי הע"ע של <math>A^T A</math></li> <li><math>v_i</math> הם הו"ע של <math>A^T A</math></li> <li><math>u_i</math> הם הו"ע של <math>A A^T</math></li> </ul> <b>קירוב מטריצה עם מטריצה מדרגה קטנה ופירוק SVD:</b> נחפש <math>B</math> הממזערת את <math>  A - B  _F =   \Sigma - U^T B V  _F</math> כאשר <math>A = U \Sigma V^T</math>  נבחר את <math>B = U \Sigma_B V^T</math> כאשר <math>\Sigma_B</math> נבחר את <math>\text{rank}(B)</math> הערכים הסינגולריים הגדולים ביותר של <math>A</math>.</p>	<p><b>מספר מצב (Condition Number):</b> מסומן <math>\kappa(A)</math> מתקיים <math>\frac{  \delta x  }{  x  } \leq   A^{-1}     A   \left( \frac{  \delta b  }{  b  } + \frac{  \delta A  }{  A  } \right)</math> כאשר <math>\kappa(A) =   A^{-1}     A   \stackrel{2-norm}{\cong} \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}</math>  ו-<math>\sigma_{\max}(A) = \max_i \sqrt{\mu_i}</math> עבור <math>\lambda_i</math> ע"ע של <math>A^T A</math>.  מטריצה עם מספר מצב גדול נקראת מטריצה "חולנית" ועלולה ליצור שגיאות גדולות.</p>	<p><b>פתרון מערכת משוואות:</b> <math>Ax = b</math>  <b>טענה:</b> קיים פתרון יחיד אם <math>A</math> full rank, אחרת יש אינסוף פתרונות או שאין פתרון כלל.  <b>Gaussian Elimination, LU, pivoting:</b> קיים פירוק <math>PA = LU</math> ומתקיים: <math>Ax = P^T L U x = b</math>  <math>x = U^{-1} y, y = L^{-1} (Pb)</math>  הפיכת מטריצה: <math>A^{-1} = U^{-1} Y, Y = L^{-1} I</math>  * אם <math>A</math> הפיכה אז קיים לה פירוק יחיד  * אם <math>A</math> SPD אז קיים פתרון ללא Pivot  * <math>\det(A) = \det(LU) = \det(U)</math>  <b>Cholesky למטריצות SPD:</b> אם <math>A</math> היא SPD קיימת <math>L</math> משולשית תחתונה עם <math>l_{i,i} &gt; 0</math> כך ש-<math>A = LL^T</math>  <math>\det(A) = \det(LL^T) = \det(L)^2</math>  <b>Thomas למערכת תלת אלכסונית:</b> האלגוריתם מצליח כאשר המטריצה <math>A</math> היא SPD SDD.  <b>פירוק QR:</b> עבור <math>A = QR</math> נקבל <math>b = R^T Q^T x</math>.</p>
<p><b>מטריצת Householder:</b> מטריצת Householder היא מטריצה אורתוגונלית מהצורה <math>Q = I - 2ww^T</math>  לכל וקטור <math>v</math> מתקיים <math>Qv =   v  _2 e_1</math>  עבור <math>  v  _2 = \beta</math> הוקטור <math>w</math> מוגדר כך: <math>w = \frac{v - \beta e_1}{  v - \beta e_1  _2}</math></p>	<p><b>Power method:</b> למציאת ו"ע עם גודל ביותר. בהינתן ניחוש התחלתי <math>x^{(0)}</math>: <math>x^{(k+1)} = \frac{(Ax^{(k)})}{  Ax^{(k)}  }</math>  לכל <math>A</math> לכסינה עם ע"ע <math> \lambda_1  \geq  \lambda_2  \geq \dots \geq  \lambda_n </math>:  <math>\lim_{k \rightarrow \infty} \{x^{(k)}\} = v_1; \lim_{k \rightarrow \infty} \frac{(x^{(k)})^T A x^{(k)}}{(x^{(k)})^T x^{(k)}} = \lambda_1</math>  <b>הערה:</b> עבור <math>A^{-1}</math> השיטה תחזיר את <math>v_n, \lambda_n</math> ו"ע עם ע"ע קטן ביותר  <b>Inverse Power method:</b> מציאת ו"ע של ע"ע נתון. בהינתן ניחוש לע"ע <math>\mu</math> וניחוש התחלתי ל"ע <math>x^{(0)}</math>:  <math>x^{(k+1)} = (A - \mu I)^{-1} x^{(k)}; x^{(k+1)} \leftarrow \frac{x^{(k+1)}}{  x^{(k+1)}  }</math>  פקטור ההתכנסות ל-I.P.M. הינו <math>\frac{  \mu - \lambda_{\text{closest to } \mu}  }{  \mu - \lambda_{\text{second closest to } \mu}  }</math></p>	

<p><b>Penalty and Barrier methods:</b> את בעיות האופטימיזציה עם אילוץ אי שוויון ושוויון שראינו ב-(*) נכתוב כך: (***) = <math>\min_{x \in \mathbb{R}^n} f(x) + \mu \left( \sum_{j=1}^{m_{eq}} \rho_j (c_j^{eq}(x))^2 + \sum_{l=1}^{m_{ineq}} \rho_l (\max\{0, c_l^{ineq}(x)\}) \right)</math> עבור <math>\rho_j(x), \rho_l(x) &gt; 0</math> ו-<math>\{\rho_j(x)\}</math> פונקציות סקלריות החסומות מלמטה ב-0 (לרוב <math>\rho(x) =  x ^2</math>). עבור <math>\mu \rightarrow \infty</math> הפתרון יהיה זהה לפתרון של (*). בפועל נפתור בצורה איטרטיבית עם ניחוש התחלתי <math>x^{(0)}</math> את (***) עם <math>\mu_0 &lt; \mu_1 &lt; \dots &lt; \infty</math> ובכל איטרציה הקלט יהיה <math>x^{(k)}</math> מהאיטרציה הקודמת.</p>	<p>מטריצת אילוץי האי שוויון מטריצת הגרדיאנטים של אילוץי האי שוויון <math>J^{ieq}(x) = \begin{bmatrix} -\nabla c_1^{ieq}(x) \\ \vdots \\ -\nabla c_{m_{ieq}}^{ieq}(x) \end{bmatrix}</math> <math>c^{ieq}(x) = \begin{bmatrix} -c_1^{ieq}(x) \\ \vdots \\ -c_{m_{ieq}}^{ieq}(x) \end{bmatrix}</math> וקטור כופלי לגראנז': <math>(\lambda^{ieq})^T = [\lambda_1 \dots \lambda_{m_{ieq}}]</math> פונקציית לגראנז': <math>\mathcal{L}(x, \lambda^{eq}, \lambda^{ieq}) = f(x) + (\lambda^{eq})^T c^{eq}(x) + (\lambda^{ieq})^T c^{ieq}(x)</math> נחפש <math>x^*, \lambda^{eq*}, \lambda^{ieq*}</math> כך שמתקיים <math>\nabla_x \mathcal{L}(x^*, \lambda^{eq*}, \lambda^{ieq*}) = \nabla f(x^*) + (J^{eq})^T \lambda^{eq*} = 0</math> <math>\nabla \mathcal{L}_{\lambda^{ieq}}(x^*, \lambda^{eq*}, \lambda^{ieq*}) = 0</math> ו-<math>\nabla \mathcal{L}_{\lambda^{eq}}(x^*, \lambda^{eq*}, \lambda^{ieq*}) = 0</math> הערה: נחפש <math>\lambda^{ieq*}</math> שכל איבריו <math>0 \leq</math> ויש בו כמה שיותר אפסים. נקודה <math>x^*</math> עם <math>\lambda^{eq*}, \lambda^{ieq*}</math> מתאימים היא מינימום אם לכל <math>y \in \mathbb{R}^n</math> המתקיים <math>y^T \nabla_x \mathcal{L}(x^*, \lambda^{eq*}, \lambda^{ieq*}) = 0</math> ו-<math>y^T \nabla_x^2 \mathcal{L}(x^*, \lambda^{eq*}, \lambda^{ieq*}) y \geq 0</math></p>	<p>שיטות איטרטיביות לפתרון מערכת משוואות: <math>Ax = b</math> עבור ניחוש התחלתי <math>x^{(0)}</math> השיטה תוגדר כך <math>x^{(k+1)} = \phi(x^{(k)})</math> קצב ההתכנסות <math>\lim_{k \rightarrow \infty} \frac{\ x^{(k+1)} - x^*\ }{\ x^{(k)} - x^*\ } = C \leq \rho(I - M^{-1}A)</math> p מגדיר את קצב ההתכנסות ו-C הוא ה-Convergence factor. ההתכנסות היא לינארית כאשר <math>p = 1</math> ו-<math> C  &lt; 1</math>. וקטור השגיאה: <math>e^{(k)} = x^* - x^{(k)}</math> (לא ניתן לחישוב כי <math>x^*</math> נעלם) וקטור השארית: <math>r^{(k)} = b - Ax^{(k)} = Ae^{(k)}</math> השארית אנכית לעמודות המטריצה, כלומר <math>A^T(b - Ax) = 0</math> נרצה שיתקיים <math>\lim_{k \rightarrow \infty} \{e^{(k)}\} = \lim_{k \rightarrow \infty} \{r^{(k)}\} = 0</math> תנאי עצירה <math>\frac{\ Ax^{(k)} - b\ }{\ b\ } &lt; \epsilon</math> או <math>\frac{\ x^{(k)} - x^{(k-1)}\ }{\ x^{(k)}\ } &lt; \epsilon</math> כתיב מטריציוני: <math>A = M + N</math> ולכן <math>b = Mx + Nx</math> ונפתור <math>x^{(k+1)} = M^{-1}(b - Nx^{(k)}) = x^{(k)} + M^{-1}(b - Ax^{(k)})</math> שיטת ריצ'רדסון (Richardson): <math>x^{(k+1)} = x^{(k)} + \frac{1}{c}(b - Ax^{(k)})</math>, <math>c &gt; 0</math> עבור <math>M = cI</math> שיטת ג'ייקובי הממושקלת (Jacobi): <math>0 &lt; \omega \leq 1</math>, אם <math>\omega = 1</math> נקבל את שיטת ג'ייקובי הרגילה, <math>D_{i,i} = A_{i,i}</math>, <math>M_j = D = \text{diag}(A)</math>. <math>A = L + D + U</math> ו-<math>x^{(k+1)} = x^{(k)} + \omega D^{-1}(b - Ax^{(k)})</math> ונקבל <math>x^{(k+1)} = (1 - \omega)x^{(k)} + \omega D^{-1}(b - (L + U)x^{(k)})</math> או <math>x_i^{(k+1)} = (1 - \omega)x_i^{(k)} + \omega \frac{1}{a_{i,i}}(b_i - \sum_{j \neq i} a_{i,j}x_j^{(k)})</math> שיטת גאוס זיידל ממושקלת (Gauss-Seidel): <math>0 &lt; \omega \leq 1</math>, אם <math>\omega = 1</math> נקבל את שיטת גאוס זיידל הרגילה, <math>M = (L + D)^{-1}</math>. <math>x^{(k+1)} = (\omega L + D)^{-1}((1 - \omega)Dx^{(k)} + \omega(b - Ux^{(k)}))</math> או <math>x_i^{(k+1)} = \frac{1}{a_{i,i}}(b_i - \sum_{j &lt; i} a_{i,j}x_j^{(k+1)} - \sum_{j &gt; i} a_{i,j}x_j^{(k)})</math> התכנסות שיטות איטרטיביות: וקטור השגיאה הינו <math>e^{(k+1)} = (I - M^{-1}A)^k e^{(0)}</math>. אם <math>\rho(I - M^{-1}A) &lt; 1</math> אז השיטה מתכנסת לכל <math>x^{(0)}</math>. טענה: בגאוס זיידל וג'ייקובי, אם <math>A</math> היא SDD אז השיטות מתכנסות. טענה: אם <math>A</math> היא לא סימטרית אז גאוס זיידל מתכנסת. טענה: אם <math>A</math> היא חיובית מוגדרת אז גאוס זיידל מתכנסת. טענה: גאוס זיידל שקולה למינימיזציה של <math>f(x) = \frac{1}{2} \ x - x^*\ _A^2 = \frac{1}{2} x^T A x - x^T b + \frac{1}{2} (x^*)^T b</math> שיטת Steepest Descent: אם <math>A</math> היא SPD אז <math>\nabla f(x) = Ax - b</math> <math>f(x) = \frac{1}{2} \ x - x^*\ _A^2 = \frac{1}{2} x^T A x - x^T b + \frac{1}{2} (x^*)^T b</math> השיטה תוגדר כך: <math>x^{(k+1)} = x^{(k)} - \alpha \nabla f(x^{(k)}) = x^{(k)} + \alpha(b - Ax^{(k)})</math> עבור <math>\alpha_{opt} = \frac{(r^{(k)})^T A e^{(k)}}{(r^{(k)})^T A r^{(k)}} = \frac{(r^{(k)}, r^{(k)})}{(r^{(k)}, A r^{(k)})}</math> התכנסות שיטת Steepest Descent: עבור <math>f(x)</math> הנ"ל <math>\rho(I - \alpha A) = \max\{ 1 - \alpha \lambda_{\max} ,  1 - \alpha \lambda_{\min} \}</math> ו-<math>\rho_{min} = 1 - \frac{2}{\kappa(A)}</math>, <math>\alpha_{opt} = \frac{2}{\lambda_{\max} + \lambda_{\min}}</math> שיטת (CG) Conjugate gradients: טענה: אם <math>A</math> היא SPD ו-full rank אז CG מתכנסת אחרי n איטרציות לכל היותר. עבור כל ניחוש התחלתי.</p>
<p><b>The projected Steepest Descent method:</b> נדגם שבכל איטרציה נהיה בתוך התחום שמקיים את האילוץ (feasible). עבור ניחוש התחלתי <math>x^{(0)}</math> בכל איטרציה נבצע: <math>x^{(k+1)} = \Pi_{\Omega}(x^{(k)} - \alpha \nabla f(x^{(k)}))</math> עבור פונקציית הטלה: <math>\Pi_{\Omega}(y) = \argmin_{x \in \Omega} \ x - y\ </math></p> <p><b>משפטים שאני המצאתי:</b> <b>משפט:</b> עבור <math>x = \sum_{i=1}^n \alpha_i v_i</math> כאשר <math>(v_i, \lambda_i)</math> הם ו"ע ומתקיים <math>\max \left( \frac{\sum_{i=1}^n \alpha_i^2 \lambda_i}{\sum_{i=1}^n \alpha_i^2} \right) = \lambda_{\max}</math> <b>משפט:</b> עבור SPD A מתקיים <math>\max \frac{x^T A x}{x^T x} = \lambda_{\max}</math> וגם <math>\max \frac{x^T A^{-1} x}{x^T x} = \lambda_{\min}</math> <b>משפט:</b> בשיטות איטרטיביות לפתרון מערכת משוואות <math>\alpha_{opt}</math> הוא זה שממזער את <math>\rho(I - M^{-1}A)</math> אם <math>A \in \mathbb{R}^{m \times n}</math> מדרגה מלאה אז <math>\text{rank}(A) = \min(m, n)</math> <b>משפט:</b> אם SPD אז <math>\text{rank}(A) = \min(m, n)</math> שזה <math>\text{rank}(A)</math> שזה גם SPD. בנוסף למינורים יש דטרמיננטות שונות מ-0. <b>משפט:</b> אם B חצי מוגדרת ו-M חיובית מוגדרת אז <math>(M + B)</math> חיובית מוגדרת. בפרט אם <math>\text{full rank } A</math> אז <math>(I + A^T A)</math> חיובית מוגדרת. <b>משפט:</b> אם מכפלת מטריצות מדרגה <math>(k \times k)</math> כמלאה תונת מטריצה מסדר <math>(k \times k)</math> כאשר <math>k</math> הוא המינימלי מבין כל הדרגות אז המטריצה מדרגה מלאה.</p>	<p>אופטימיזציה ללא אילוץים: (1) נתונה פונקציה <math>f(x): \mathbb{R}^n \rightarrow \mathbb{R}</math> ונרצה למצוא <math>x^* = \argmin_{x \in \mathbb{R}^n} f(x)</math> וטור טיילור חד מימדי: <math>c \in [x, x + \epsilon]</math> <math>f(x + \epsilon) = f(x) + f'(x)\epsilon + \frac{1}{2} f''(x)\epsilon^2 + \frac{1}{3!} f'''(c)\epsilon^3</math> טור טיילור דו מימדי: <math>f(x_1 + \epsilon_1, x_2 + \epsilon_2) = f(x_1, x_2) + \frac{\partial f}{\partial x_1} \epsilon_1 + \frac{\partial f}{\partial x_2} \epsilon_2 + \frac{1}{2} \frac{\partial^2 f}{\partial x_1^2} \epsilon_1^2 + \frac{\partial^2 f}{\partial x_1 \partial x_2} \epsilon_1 \epsilon_2 + \frac{1}{2} \frac{\partial^2 f}{\partial x_2^2} \epsilon_2^2</math> עבור <math>H = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} &amp; \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_1 \partial x_2} &amp; \frac{\partial^2 f}{\partial x_2^2} \end{bmatrix}</math>, <math>\nabla f = [\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}]^T</math>, <math>\epsilon = [\epsilon_1, \epsilon_2]^T</math> ב-n מימדים <math>(H_{i,j})</math> נקבל: <math>f(x + \epsilon) = f(x) + \langle \nabla f, \epsilon \rangle + \frac{1}{2} \langle \epsilon, H \epsilon \rangle + O(\ \epsilon\ ^3)</math> (2) אם <math>f(x): \mathbb{R}^n \rightarrow \mathbb{R}</math> היא וקטור של פונקציות (ניתן לחשוב על מטריצה בגודל <math>n \times m</math>), <math>x \in \mathbb{R}^n</math>, <math>f_i(x) \in \mathbb{R}^m</math>, <math>f_i(x + \epsilon) \approx f_i(x) + \langle \nabla f_i(x), \epsilon \rangle</math> <math>f_i(x) \approx J_i \epsilon</math> (עבור <math>\epsilon \rightarrow \infty</math> נקבל שוויון) <math>J_{i,j} = \frac{\partial f_i}{\partial x_j}</math> היא מטריצת יעקוביאן, <math>J \in \mathbb{R}^{m \times n}</math> אם <math>A \in \mathbb{R}^{m \times n}</math> עבור <math>f(x) = Ax</math> אז <math>J = A</math> כלומר <math>\delta f = f(x + \epsilon) - f_i(x) = A(x + \epsilon) - Ax = A\epsilon</math> אם <math>\phi: \mathbb{R} \rightarrow \mathbb{R}</math> ו-<math>f_i(x) = \phi(x_i)</math> (כלומר <math>f</math> מיוצגת באמצעות מטריצה אז רק האיבר i-ה שונה מ-0) אז: <math>\delta f = \phi(x + \epsilon) - \phi_i(x) \approx \text{diag}(\phi'(x)) \delta x = \text{diag}(\phi'(x)) \delta x</math> ו-<math>J_{i,i} = \phi'(x_i)</math>, <math>J = \text{diag}(\phi'(x))</math> פתרון בעיית אופטימיזציה ללא אילוץים: נחפש <math>x^*</math> המקיימת <math>0 = \nabla f(x^*)</math> והיא תוכל להיות נקודת מינימום. <math>x^*</math> מינימום locally: <math>\exists r &gt; 0: f(x) \geq f(x^*) \forall x: \ x - x^*\  &lt; r</math> <math>x^*</math> מינימום globally: <math>f(x) \geq f(x^*) \forall x \in \mathbb{R}^n</math> אם <math>H</math> חיובית מוגדרת, <math>x^*</math> מינימום locally אם <math>\nabla f(x^*) = 0</math></p>	<p>אופטימיזציה עם אילוץים: צורה כללית לאופטימיזציה עם אילוץים: <math>(*) = \min_{x \in \mathbb{R}^n} f(x) \text{ subject to } \begin{cases} c_j^{eq}(x) = 0 &amp; j = 1, \dots, m_{eq} \\ c_l^{ineq}(x) \leq 0 &amp; l = 1, \dots, m_{ineq} \end{cases}</math> <b>Feasible set:</b> קבוצת הפתרונות שמקיימים את האילוץים. <math>\Omega = \{x   c_j^{eq}(x) = 0, j = [1, m_{eq}]; c_l^{ineq}(x) \leq 0, l = [1, m_{ineq}]\}</math> ניתן להגדיר את הבעיה כך: <math>(*) = \min_{x \in \Omega} f(x)</math> <math>x^*</math> הוא פתרון locally ל-<math>(*)</math> אם <math>x^* \in \Omega</math> וגם קיים <math>\mathcal{N}</math> המקיימת <math>f(x) \geq f(x^*) \forall x \in \mathcal{N} \cap \Omega</math></p> <p><b>אופטימיזציה עם אילוץי שוויון:</b> <math>(**) = \min_{x \in \mathbb{R}^n} f(x) \text{ subject to } c_j^{eq}(x) = 0 \quad j = 1, \dots, m_{eq}</math> מטריצת אילוץי השוויון מטריצת הגרדיאנטים של אילוץי השוויון <math>J^{eq}(x) = \begin{bmatrix} -\nabla c_1^{eq}(x) \\ \vdots \\ -\nabla c_{m_{eq}}^{eq}(x) \end{bmatrix}</math> <math>c^{eq}(x) = \begin{bmatrix} -c_1^{eq}(x) \\ \vdots \\ -c_{m_{eq}}^{eq}(x) \end{bmatrix}</math> וקטור כופלי לגראנז': <math>(\lambda^{eq})^T = [\lambda_1 \dots \lambda_{m_{eq}}]</math> פונקציית לגראנז': <math>\mathcal{L}(x, \lambda^{eq}) = f(x) + (\lambda^{eq})^T c^{eq}(x)</math> נחפש <math>x^*</math> ו-<math>\lambda^{eq*}</math> כך שמתקיים: <math>\nabla \mathcal{L}_{\lambda^{eq}}(x^*, \lambda^{eq*}) = 0</math> <math>\nabla_x \mathcal{L}(x^*, \lambda^{eq*}) = \nabla f(x^*) + (J^{eq})^T \lambda^{eq*} = 0</math> נקודה <math>x^*</math> עם כופלי לגראנז' מתאימים <math>\gamma \geq 0</math> מתקיים <math>y^T \nabla_x^2 \mathcal{L}(x^*, \lambda^{eq*}) y \geq 0</math> ו-<math>y^T \nabla_x^2 \mathcal{L}(x^*, \lambda^{eq*}) y \geq 0</math> אופטימיזציה עם אילוץי שוויון ואי שוויון: הצורה הכללית היא (*). <b>אילוץ אי שוויון פעיל:</b> קיים פתרון <math>x^*</math> כך שמתקיים <math>c_l^{ieq}(x^*) = 0</math> <math>\mathcal{A}(x)</math> היא קבוצת האינדקסים של אילוץי אי שוויון פעילים <b>אילוץ אי שוויון לא פעיל:</b> קיים פתרון <math>x^*</math> כך שמתקיים <math>c_l^{ieq}(x^*) &lt; 0</math></p>
<p><b>קמירות:</b> (1) <math>S \in \mathbb{R}^n</math> קבוצה קמורה אם לכל <math>x, y \in S, \alpha \in [0, 1]</math> <math>\alpha x + (1 - \alpha)y \in S</math> (2) פונקציה קמורה אם ה-domain שלה הוא קבוצה קמורה ולכל <math>x, y, \alpha \in [0, 1]</math> <math>f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)</math> (3) פונקציה קמורה אם היא גזירה ולכל <math>x_1, x_2</math> מתקיים <math>f(x_1) \geq f(x_2) + \langle \nabla f(x_2), x_1 - x_2 \rangle</math> (4) פונקציה קמורה אם היא גזירה פעמיים ומתקיים <math>\nabla^2 f(x) \geq 0</math>, <math>H = \nabla^2 f(x) \geq 0</math> כלומר <math>H</math> מטריצה חיובית חצי מוגדרת (5) פונקציה קמורה אם היא גזירה locally <math>x^*</math> או כל נקודה המקיימת <math>\nabla f(x^*) = 0</math> היא מינימום globally</p>	<p><b>שיטות איטרטיביות לבעיות אופטימיזציה ללא אילוץים:</b> <b>שיטת steepest descent:</b> נבחר בכל איטרציה <math>x^{(k+1)} = x^{(k)} - \alpha M \nabla f(x^{(k)})</math> (ניתן לבחור <math>M = I</math>) הוא כיוון ירידה כאשר מתקיים: <math>\langle \nabla f, d^{(k)} \rangle &lt; 0</math>. כיוון הירידה הוא מינוס הגרדיאנט: <math>-\nabla f(x^{(k)})</math>, שהוא כיוון הירידה המירבי של הפונקציה f. כל כיוון <math>d = -M \nabla f(x^{(k)})</math> כך ש-M חיובית מוגדרת הוא כיוון ירידה.</p> <p><b>שיטת Newton:</b> אם H הפיכה אז בכל איטרציה נבחר <math>d = -H^{-1} \nabla f(x^{(k)})</math> עבור <math>x^{(k+1)} = x^{(k)} + d</math> <b>שיטת Quasi Newton:</b> נחליף את B-<math>M(x^{(k)})</math> ואז בכל איטרציה נבחר <math>x^{(k+1)} = x^{(k)} + d</math> עבור <math>d = -\left(M(x^{(k)})\right)^{-1} \nabla f(x^{(k)})</math> (למשל M שווה לאלכסון של H וכך היא הפיכה) <b>שיטת Line Search:</b> בכל איטרציה נבחר <math>d^{(k)}</math> ונחפש <math>\alpha</math> כך שמתקיים <math>x^{(k+1)} = x^{(k)} + \alpha d^{(k)}</math> (כאן ההתייחסות היא לבחירת <math>\alpha</math> הנחה שאת <math>\alpha</math> אנו יודעים לבחור). נרצה לבחור <math>\alpha^{(k)}</math> מינימלית, כלומר עבור <math>\phi(\alpha) = f(x^{(k)} + \alpha d^{(k)})</math> נרצה למצוא <math>\alpha^{(k)} = \argmin_{\alpha} \phi(\alpha)</math> <b>Backtracking line search using Armijo condition:</b> נבחר <math>\alpha^{(0)}</math> די גדול, <math>0 &lt; \beta &lt; 1</math> (בדרך"כ <math>\frac{1}{2}</math>), <math>0 &lt; c &lt; 1</math> (בדרך"כ <math>10^{-4}</math>). בכל איטרציה נבחר <math>\alpha_j^{(k)} = \beta^j \alpha^{(0)}</math> עבור <math>j = 0, 1, 2, \dots</math> עד שמתקיים: <math>f(x^{(k)} + \alpha_j^{(k)} d^{(k)}) \leq f(x^{(k)}) + c \alpha_j^{(k)} \langle \nabla f, d^{(k)} \rangle</math> <b>שיטת Coordinate descent:</b> בכל איטרציה נעדכן את הקואורדינטה ה-i של x. נניח <math>x_j</math> קבועים לכל <math>j \neq i</math> ובחר <math>x_i</math> המקיים <math>\frac{\partial f}{\partial x_i} = 0</math>. ניתן לעבור על ה-i סדרתית או אקראית (העיקר לעדכן את כולם).</p>	<p>מטריצת אילוץי השוויון מטריצת הגרדיאנטים של אילוץי השוויון <math>J^{eq}(x) = \begin{bmatrix} -\nabla c_1^{eq}(x) \\ \vdots \\ -\nabla c_{m_{eq}}^{eq}(x) \end{bmatrix}</math> <math>c^{eq}(x) = \begin{bmatrix} -c_1^{eq}(x) \\ \vdots \\ -c_{m_{eq}}^{eq}(x) \end{bmatrix}</math> וקטור כופלי לגראנז': <math>(\lambda^{eq})^T = [\lambda_1 \dots \lambda_{m_{eq}}]</math> פונקציית לגראנז': <math>\mathcal{L}(x, \lambda^{eq}) = f(x) + (\lambda^{eq})^T c^{eq}(x)</math> נחפש <math>x^*</math> ו-<math>\lambda^{eq*}</math> כך שמתקיים: <math>\nabla \mathcal{L}_{\lambda^{eq}}(x^*, \lambda^{eq*}) = 0</math> <math>\nabla_x \mathcal{L}(x^*, \lambda^{eq*}) = \nabla f(x^*) + (J^{eq})^T \lambda^{eq*} = 0</math> נקודה <math>x^*</math> עם כופלי לגראנז' מתאימים <math>\gamma \geq 0</math> מתקיים <math>y^T \nabla_x^2 \mathcal{L}(x^*, \lambda^{eq*}) y \geq 0</math> ו-<math>y^T \nabla_x^2 \mathcal{L}(x^*, \lambda^{eq*}) y \geq 0</math> אופטימיזציה עם אילוץי שוויון ואי שוויון: הצורה הכללית היא (*). <b>אילוץ אי שוויון פעיל:</b> קיים פתרון <math>x^*</math> כך שמתקיים <math>c_l^{ieq}(x^*) = 0</math> <math>\mathcal{A}(x)</math> היא קבוצת האינדקסים של אילוץי אי שוויון פעילים <b>אילוץ אי שוויון לא פעיל:</b> קיים פתרון <math>x^*</math> כך שמתקיים <math>c_l^{ieq}(x^*) &lt; 0</math></p>